

Base de Airtable: "Proyecto Final"

Tabla: Pacientes

Campo	Tipo	Descripción
Nombre	Texto	Nombre completo del paciente registrado.
DNI ficticio	Número	Identificador único usado para matchear contra el mensaje del paciente. Se compara como número, no como texto, para evitar falsos negativos por formato.
Turnos	Link a otro registro	Relación inversa hacia la tabla Turnos (uno a muchos). Evita que los turnos queden aislados del paciente que los solicitó.

Tabla: Turnos

Campo	Tipo	Descripción
Paciente	Link a Pacientes	Relación con el registro de la tabla Pacientes encontrado en la búsqueda.
Especialidad	Texto	Extraído dinámicamente por el AI Agent a partir del mensaje libre del paciente.
Fecha de preferencia	Texto	Fecha u horario preferido, también extraído por IA.
Estado	Selección única	Campo de estado obligatorio del ciclo de vida: Pendiente aprobacion → Aprobado por humano ó Rechazado.
Solicitud original	Texto largo	Mensaje textual tal cual lo escribió el paciente, guardado para trazabilidad y auditoría.
Chat ID paciente	Número	ID de chat de Telegram, usado para poder responderle al paciente correcto una vez resuelto el HITL.

Tabla: Errores

Campo	Tipo	Descripción
Mensaje	Texto largo	Descripción del error capturado (fallo de API de IA, de Airtable o de Gmail).
Nodo	Texto	Nombre del nodo de n8n donde ocurrió la falla, para depuración rápida.
Datos de entrada	Texto largo	Volcado JSON del ítem que se estaba procesando al momento del fallo.
Fecha	Fecha/hora	Timestamp ISO del momento exacto del error.

Relación entre tablas: Pacientes 1—N Turnos. Cada turno referencia siempre a un paciente real ya validado en la búsqueda previa (nunca se crea un turno sin vínculo), y el campo Estado permite filtrar/auditar en qué parte del proceso está cada solicitud sin necesidad de leer los logs de ejecución de n8n.

Esquemas JSON de Transferencia entre Integraciones

Estos son fragmentos cortos que muestran cómo viaja la información entre los distintos servicios del flujo — no son el archivo completo del workflow (ese ya está subido por separado en el repositorio).

a) *Trigger → Normalizar Input (Telegram webhook)*

```
{
  "message": {
    "text": "Hola, mi DNI es 30111222, quiero un turno de cardiologia para el 20 de octubre",
    "chat": { "id": 123456789 },
    "from": { "first_name": "Juan" }
  }
}
```

b) *AI Agent (Gemini) → Buscar Paciente (salida estructurada)*

El Structured Output Parser obliga al modelo a responder siempre con este contrato, evitando texto libre que rompa el resto del flujo:

```
{
  "output": {
    "dni": 30111222,
    "especialidad": "cardiologia",
    "fecha_preferida": "20 de octubre"
  }
}
```

c) *Airtable (Buscar Paciente) → Crear Turno Pendiente*

```
{
  "id": "recXXXXXXXXXXXXXXXX",
  "fields": {
    "Nombre": "Juan Perez",
    "DNI ficticio": 30111222
  }
}
```

d) *Gmail sendAndWait → IF - Aprobado (respuesta humana)*

```
{
  "data": {
    "approved": true
  }
}
```

Optimización de Costos — Matriz de Decisión

El sistema usa un único motor de IA en producción (Gemini Flash), pero la arquitectura fue diseñada para poder derivar tareas a otros modelos según su complejidad, siguiendo el criterio de "el modelo más barato que resuelve la tarea correctamente".

Tarea	Modelo asignado	Justificación	Costo aprox. / 1000 ejecuciones*
Extracción de datos estructurados de un mensaje corto (DNI, especialidad, fecha)	Gemini Flash (usado en producción)	Tarea simple, de baja profundidad de razonamiento, con salida corta y estructurada. Un modelo "flash" de bajo costo resuelve esto con la	~ USD 0.10 - 0.30

Tarea	Modelo asignado	Justificación	Costo aprox. / 1000 ejecuciones*
		misma calidad que uno grande, a una fracción del costo.	
Lectura de historia clínica extensa o documentos adjuntos (no implementado aún, roadmap)	Claude (lectura densa / contexto largo)	Para documentos largos con matices clínicos, un modelo de mayor capacidad de comprensión de contexto reduce el riesgo de omitir información relevante.	~ USD 3 - 6
Clasificación masiva retroactiva de turnos históricos (reprocesar registros fuera de horario)	Batch API (OpenAI o Anthropic)	Al no requerir respuesta en tiempo real, procesar en lote aprovecha descuentos de hasta 50% frente al precio de la API síncrona.	~ 50% del costo síncrono equivalente
Generación de mensajes de confirmación/rechazo al paciente	Sin modelo (texto fijo con variables)	No hay razonamiento involucrado, es un template con variables dinámicas. Usar un LLM acá sería gastar tokens de forma innecesaria.	USD 0

* Estimación orientativa a tarifas públicas vigentes de cada proveedor al momento de este informe; puede variar.

Medidas de control de costos ya implementadas en el flujo

- Modelo Flash como default: se usa la variante más económica de Gemini para la única tarea de IA del flujo.
- Salida acotada: el Structured Output Parser limita la respuesta a 3 campos cortos, evitando que el modelo divague y consuma tokens de más.
- Temperatura baja (0.2): reduce reintentos por respuestas inconsistentes o mal formateadas.
- Trigger reactivo (webhook de Telegram): el flujo solo consume recursos cuando un paciente escribe, no hace polling constante.

Seguridad y Resiliencia

Minimización de datos

- El Agente de IA solo recibe el texto del mensaje del paciente — nunca se le envían datos sensibles adicionales (historia clínica, teléfono, dirección) que no sean necesarios para la extracción.
- El campo DNI ficticio se usa únicamente como clave de búsqueda interna; no se expone en los mensajes de confirmación al paciente.
- El prompt del sistema prohíbe explícitamente a la IA inventar datos que el paciente no proveyó, evitando que se generen registros con información ficticia.

Rutas de error (Error Handlers)

En vez de encadenar una rama de error en cada nodo (lo cual generaría un diagrama difícil de auditar), el flujo concentra el manejo de errores en los 3 puntos donde una llamada a una API externa puede fallar de verdad:

Nodo con posible falla	Tipo de fallo cubierto	Acción de resiliencia
Extraer Datos Turno (AI Agent)	Timeout o error de la API de Gemini	onError: continueErrorOutput → registra el error y no rompe la ejecución completa.
Buscar Paciente (Airtable)	Error de autenticación o de base caída	Igual manejo: continúa hacia "Registrar Error" en vez de abortar todo el workflow.
Gmail - Aprobación HITL	Fallo al enviar el mail de aprobación	Se registra el error y el turno queda trazado en la tabla Errores para revisión manual.

Adicionalmente, el nodo IF - Datos Validos actúa como filtro contra datos incompletos: si la IA no logra identificar un DNI real en el mensaje (queda en 0), el flujo corta antes de tocar la base de datos y le pide al paciente que reformule el pedido, en vez de generar un registro corrupto.

Punto de Human-in-the-Loop (HITL)

Antes de confirmarle un turno a un paciente (acción crítica de cara al negocio), el sistema:

- 1. Crea el turno en Airtable con Estado = Pendiente aprobacion (nunca se contacta al paciente en este punto).
- 2. Envía un mail a recepción mediante Gmail - Aprobación HITL usando la operación nativa sendAndWait, con botones de Aprobar / Rechazar y un límite de espera de 24hs.
- 3. El flujo queda pausado (sin consumir recursos) hasta que un humano responde.
- 4. Recién ahí se actualiza el Estado del turno y se le informa el resultado al paciente por Telegram.

Checklist de seguridad de la consigna

Ítem	Estado	Cómo se resuelve
¿Filtro contra bucles infinitos?	Sí	El flujo es reactivo (un trigger = una ejecución lineal); no hay loops ni nodos que se vuelvan a disparar a sí mismos.
¿Comparación de tipos correctos en filtros?	Sí	El campo DNI ficticio es numérico en Airtable y se compara contra un número extraído por la IA (nunca texto vs. número).
¿Prompt de IA dinámico, sin datos hardcoded?	Sí	El prompt usa la variable del mensaje real; ningún dato de paciente está fijo en el código.